

Statistique Descriptive

Semestre 3

MIP - I3A

2024 - 2025

Pr. H. FERJOUCHIA

Table des matières

1	Introduction générale	2
1.1	Introduction	2
1.2	Terminologie de base	2
2	Statistique descriptive unidimensionnelle	6
2.1	Données brutes	6
2.2	Série statistique	7
2.3	Les distributions de fréquences	7
2.3.1	Cas d'un caractère qualitatif	7
2.3.2	Cas d'une variable statistique discrète	8
2.3.3	Cas d'une variable statistique continue	9
2.4	Représentations graphiques	11
2.4.1	Représentation d'une distribution à caractère qualitatif . .	11
2.4.2	Représentation d'une distribution à caractère quantitatif .	13
2.5	Les paramètres de position	17
2.5.1	La médiane " <i>Me</i> "	17
2.5.2	Le mode " <i>Mo</i> "	20
2.5.3	Les moyennes	21
2.6	Les paramètres de dispersion	23
2.6.1	Les quantiles	23
2.6.2	Indicateurs de dispersion par rapport à la moyenne	24
2.6.3	Moments d'une série statistique	28
2.6.4	Changement d'origine et d'unité	28
2.7	Paramètre de forme	29
3	Statistique descriptive bidimensionnelle	31
3.1	Représentation graphique du nuage de points	31
3.2	Moments et la covariance	32
3.3	Le coefficient de corrélation	33
3.3.1	Coefficient de détermination	34
3.4	Les droites de régression	35

Chapitre 1

Introduction générale

1.1 Introduction

de nombreux domaines de la connaissance pratique s'appuient sur l'étude de collections homogènes d'objets ou de personnes. La statistique est un ensemble de méthodes permettant de dégager les caractéristiques ou la répartition de ces objets en fonction de critères d'étude déterminés.

La statistique est une branche des mathématiques basée sur les observations d'événements réels à partir desquelles on cherche à établir des hypothèses plausibles en vue de prévisions concernant des circonstances analogues. L'étude d'un problème statistique peut se décomposer en quatre étapes : recueil de données, classement et réduction de ces données (statistique descriptive), analyse de ces données visant à la déduction de prévisions (statistique inférentielle).

La science des statistiques peut être décomposée en deux grandes parties :

1. **La statistique descriptive** (déductive) est la phase de la statistique qui se limite à décrire ou analyser une population donnée, sans tirer de conclusion pour une population plus grande. Son but principal est de présenter l'information d'une façon compréhensible et utilisable, par exemple en calculant des moyennes, en construisant des histogrammes, en établissant des tableaux croisés, en représentant graphiquement les données, etc.
2. **La statistique inférentielle** (inductive) est l'ensemble des techniques visant à modéliser un ensemble de données en vue d'une extrapolation éventuelle à un ensemble plus vaste. Par essence cette démarche est risquée et s'oppose à la démarche déductive (non risquée) qui applique les caractéristiques d'une propriété en général à des cas particuliers et qu'on rencontre généralement en mathématique.

1.2 Terminologie de base

Dans cette section, nous présentons plusieurs termes statistiques largement utilisés qui auront une utilisation fréquente par la suite et qu'il convient de bien connaître.

• Population

Le **population statistique** est l'ensemble des éléments sur lesquels porte l'étude. On peut citer par exemple, la population des étudiants, la population des arbres, la population des mammifères, etc.

• Échantillon

Un sous-ensemble de la population sélectionné pour être étudié. L'échantillon doit être représentatif de la population afin que les conclusions puissent être généralisées à l'ensemble.

• Individu ou Unité statistique

Tout élément de la population étudiée est appelé individu (ou unité statistique). Par exemple dans la population des habitants du Maroc, **l'unité statistique** est toute personne marocaine ou étrangère habitant au Maroc. Par contre, dans la population des marocains, **l'unité statistique** est toute personne de nationalité marocaine vivant au Maroc ou l'étranger.

Le nombre d'unité statistique composant une population est appelé effectif.

• Enquête

est une méthode de recherche utilisée pour collecter des données et obtenir des informations sur un sujet spécifique. Contrairement à un sondage, qui se concentre généralement sur des réponses courtes et précises à un ensemble prédéfini de questions, une enquête peut impliquer une collecte plus approfondie de données, y compris des entretiens, des observations ou des analyses plus détaillées.

• Sondage

est une méthode de collecte de données utilisée pour recueillir des informations auprès d'un échantillon de la population afin d'obtenir des conclusions générales sur l'ensemble de la population. Il s'agit d'une technique largement utilisée en statistique pour estimer les caractéristiques ou les opinions d'une population plus large en se basant sur un échantillon représentatif.

• Données (statistiques)

Le terme de données est très utilisé en statistique. Il désigne l'ensemble des individus observés (ceux de l'échantillon), l'ensemble des variables considérées et les observations de ces variables sur ces individus.

• Caractère ou variable statistique

Un individu donné de la population peut être étudié selon certaines propriétés. Ces propriétés sont appelées **caractères ou variables statistiques**. Par exemple dans la population des étudiants chaque étudiant peut être caractérisé par son âge, son milieu d'origine et par son niveau, etc.

• Modalités

Les valeurs prises par le caractère sont appelées les modalités. Par exemple le caractère "nationalité" peut avoir comme modalités : marocaine, algérienne et tunisienne. Le caractère "nombre d'enfants par famille" peut avoir comme modalités : zéro enfant, un enfant, deux enfants et plus de deux enfants.

• Caractère qualitatif

Lorsque les modalités d'un caractère ne peuvent pas s'exprimer par des nombres, le caractère est dit qualitatif. C'est un caractère non mesurable. Par exemple, le caractère "nationalité" est qualitatif, il peut avoir comme modalités : marocaine, algérienne et tunisienne, etc. Le caractère "marque de voiture" est qualitatif, il peut avoir comme modalités : renaut, peugeot, mercedes, etc.

• Caractère quantitatif

Un caractère est dit quantitatif s'il est mesurable et on l'appelle variable statistique. Par exemple le caractère "nombre d'enfants par famille" est quantitatif, il peut avoir comme modalités : 0, 1, 2, 3, etc, le caractère "âge" est quantitatif, il peut avoir comme modalités : moins de 20 ans, entre 20 et 40 ans, entre 40 et 60 ans, plus 60 ans.

On distingue alors deux types de caractère quantitatif :

- **Variable statistique discrète**

On appelle variable discrète toute variable qui ne prend que des valeurs entières. Elle correspond le plus souvent aux opérations de dénombrements. Par exemple la variable statistique "nombre de pièces par logement" est discrète, elle a comme valeurs possibles des nombres entiers : 1 pièces, 2 pièces, 3 pièces, etc.

- **Variable statistique continue**

Si les valeurs possibles d'une variable statistique peuvent prendre des valeurs décimales quelconques dans un intervalle donné, la variable statistique est dite continue. Elle correspond le plus souvent aux opérations de mesures ou mensurations. Il faut alors découper l'intervalle de variation de la variable en tranches ou classes successives. Par exemple la variable statistique "taille des individus" est continue, elle a comme valeurs possibles les classes : moins de 1,60 mètres, entre 1,60 et 1,70 mètres, entre 1,70 et 1,80 mètres, plus 1,80 mètres.

- **L'effectif ou fréquence absolue**

C'est le nombre de fois que se répète chaque modalité du caractère.

- **Fréquence relative**

C'est le part de l'effectif d'une modalité à l'effectif total.

- **Classe**

intervalles égaux ou inégaux déterminées à l'intérieur du champs de variation de la variable statistique observée

- **Série statistique**

Une série statistique est la suite des modalités d'une population donnée. Une population peut être étudiée selon une seule variable : on parle alors de série simple. Lorsqu'on s'intéresse à étudier deux variables en même temps sur une même population : on parle dans ce cas de série double.

- **Notation**

Une variable statistique, souvent représentée symboliquement par une lettre majuscule X , Y , *etc.* Les valeurs possibles de la variable statistique sont désignées par la même lettre mais en minuscule, x_i , y_i , *etc.*

Chapitre 2

Statistique descriptive unidimensionnelle

2.1 Données brutes

Les données brutes sont des informations recueillies sans tenir compte de l'ordre ou de la séquence des éléments. Elles représentent simplement les observations ou les mesures telles qu'elles ont été enregistrées, sans aucun tri, classement ou organisation particulière. Les données brutes sont souvent considérées comme la première étape dans le processus d'analyse des données, et elles nécessitent souvent un nettoyage, une transformation ou une structuration ultérieure avant d'être utilisées pour des analyses plus approfondies.

Exemple:

Les températures enregistrées à une ville du Maroc sous abri à 14 heures pour les mois de décembre, janvier et février sont consignées dans le tableau ci-dessous :

17	18	21	22	20	21	20	21	17	21
21	20	18	19	19	17	20	20	22	20
15	16	17	20	20	20	19	15	15	16
16	16	20	21	20	18	18	18	30	24
21	20	19	19	18	19	16	17	16	18
17	18	12	16	16	17	19	19	17	20
16	16	18	16	18	17	20	19	19	20
19	16	16	20	20	19	20	15	15	16
16	18	18	16	21	16	17	18	18	18

Population : les 90 jours (31 en décembre, 31 janvier et 28 en février)

Unité statistique : un jour (le 8 janvier par exemple)

Caractère : température en degré Celsius ($^{\circ}\text{C}$) relevée à 14 heures et à un endroit donné.

2.2 Série statistique

Une série statistique est une simple énumération des observations

$$x_1, x_2, x_3, \dots, x_i, \dots, x_n.$$

Ces observations étant rangées par ordre croissant :

$$x_1 \leq x_2 \leq x_3 \leq \dots \leq x_i \leq \dots \leq x_n.$$

n est le nombre total d'observations, appelé aussi effectif. Une même observation peut se répéter plusieurs fois.

2.3 Les distributions de fréquences

Lorsque les observations sont nombreuses, il est nécessaire de les condenser sous forme d'un tableau statistique appelé distribution de fréquences.

2.3.1 Cas d'un caractère qualitatif

Une distribution de fréquences d'un caractère qualitatif se présente sous forme d'un tableau très simple. La première colonne du tableau réservée à la liste des modalités M_i du caractère étudié. La deuxième colonne comporte une succession de nombres entiers n_i , appelés effectifs ou fréquences absolues. Une troisième colonne comporte une succession de nombres décimaux f_i , appelés pourcentages ou fréquences relatives.

k est le nombre de modalités.

n_i est le nombre de fois qu'on a observé la modalité M_i . n_i est dite fréquence absolue.

$f_i = \frac{n_i}{n}$ est la proportion de la modalité M_i . f_i est dite fréquence relative. Elle est le plus souvent exprimée en pourcentage

$$f_i = \frac{n_i}{n} \times 100\%$$

Remarque 2.3.1.

- La somme des fréquences absolues est évidemment égale à l'effectif n

$$n_1 + n_2 + \dots + n_k = \sum_{i=1}^k n_i$$

- La somme des fréquences relatives est toujours égale à 1

$$\sum_{i=1}^k f_i = \frac{n_1}{n} + \dots + \frac{n_i}{n} + \dots + \frac{n_k}{n} = \frac{n}{n} = 1$$

Exemple:

Une enquête sur la nationalité des touristes visitant le Maroc a concerné un échantillon de 500 touristes.

Unité statistique : un touriste

Population : l'ensemble des touristes visitant le Maroc

Caractère étudié : nationalité

Type de Caractère : qualitatif

Les résultats obtenus sont condensés dans la distribution de fréquences suivante :

Nationalité	Nombre de touristes (fréquences absolues)	Pourcentage des touristes (fréquences relatives)
Française	85	17%
Allemande	106	21,2%
Italienne	62	12,4%
Hollandaise	44	8,8%
Belge	40	8%
Américaine	70	14,0%
Autre nationalités	93	18,6%

Parmi les 500 touristes rencontrés, 85 sont de nationalité française, ce qui correspond à 17% des touristes, les Américains représentent 14% des touristes rencontrés (70 touristes).

2.3.2 Cas d'une variable statistique discrète

Une distribution de fréquences d'une variable statistique discrète se présente sous forme d'un tableau. La première colonne du tableau indique les différentes valeurs distinctes v_i de la variable statistique étudiée. Les autres colonnes comportent les différents types de fréquences.

Valeurs de la variable statistique	Fréquences absolues n_i	Fréquences relatives f_i	Fréquences absolues cumulées croissantes	Fréquences absolues cumulées décroissantes	Fréquences relatives cumulées croissantes	Fréquences relatives cumulées décroissantes
v_1	n_1	f_1	n_1	n	f_1	1
v_2	n_2	f_2	$n_1 + n_2$	$n_k + \dots + n_2$	$f_1 + f_2$	$f_k + \dots + f_2$
v_i	n_i	f_i	$n_1 + \dots + n_i$	$n_k + \dots + n_i$	$f_1 + \dots + f_i$	$f_k + \dots + f_i$
v_k	n_k	f_k	n	n_k	1	f_k
Total	n	1				

k est le nombre de valeurs distinctes.

Exemple:

Les données du premier exemple de ce chapitre sont condensées dans la distribu-

tion de fréquences suivante :

Température x_i	Nombre de jours n_i (fréquences absolues)	Pourcentage des jours f_i (fréquences relatives)	Fréquences absolues cumulées croissantes	Fréquences absolues cumulées décroissantes	Fréquences relatives cumulées croissantes	Fréquences relatives cumulées décroissantes
12	1	1,1%	1	90	1,1%	100%
15	5	5,6%	6	89	6,7%	98,9%
16	17	18,9%	23	84	25,6%	93,3%
17	10	11,1%	33	67	36,7%	74,4%
18	15	16,7%	48	57	53,4%	63,3%
19	12	13,3%	60	42	66,7%	46,6%
20	18	20%	78	30	86,7%	33,3%
21	8	8,9%	86	12	95,6%	13,3%
22	2	2,2%	88	4	97,8%	4,4%
24	1	1,1%	89	2	98,9%	2,2%
30	1	1,1%	90	1	100%	1,1%
Total	90	100%				

Remarque 2.3.2. *Aucune information quantitative n'est perdue, seuls les jours où telle température a été relevée ne sont plus connus. Il faudra veiller à ce que cette perte ne soit pas préjudiciable à l'exploitation que l'on veut faire de cette étude. Le tableau est un peu plus lisible que le précédent. On peut par exemple noter les températures les plus souvent atteintes lors de cette période. On peut déjà avoir une idée de la moyenne.*

2.3.3 Cas d'une variable statistique continue

Une distribution de fréquences d'une variable statistique continue se présente sous forme d'un tableau. La première colonne du tableau indique les différentes classes de la variable statistique étudiée. De la même manière que pour les distributions de fréquences d'une variable statistique discrète, on définit les fréquences absolues, les fréquences absolues cumulées croissantes, les fréquences absolues cumulées décroissantes, les fréquences relatives, les fréquences relatives cumulées croissantes, les fréquences relatives cumulées décroissantes.

Chaque classe est caractérisée par une borne inférieure, une borne supérieure. Une classe qui n'est pas de borne inférieure ou supérieure est dite classe ouverte.

L'amplitude d'une classe est égale à la différence entre les bornes supérieure et inférieure de la classe. Les classes peuvent avoir une amplitude constante ou variable.

$$\text{Amplitude} = \text{borne supérieure} - \text{borne inférieure}$$

Le point central d'une classe est le point correspondant au milieu de cette classe et s'obtient en ajoutant les bornes inférieure et supérieure de la classe et en divisant par deux

$$\text{Point central} = \frac{\text{borne inférieure} + \text{borne supérieure}}{2}$$

Pour construire une distribution de fréquences groupée en classes à partir des données brutes :

1. On calcule l'étendue

2. On partage l'étendue en classes suffisamment nombreuses de même amplitude. Lorsque cela est impossible, on considère des classes d'amplitudes variables ou des classes ouvertes. Le nombre de classes est habituellement compris entre 5 et 20, cela dépend des données.
3. Dans chaque classe, on détermine le nombre d'observations, pour cela il suffit de compter, à partir des données brutes, le nombre d'observations appartenant à la classe.

Exemple:

On a mesuré le poids en kilogramme de 80 personnes.

Unité statistique : une personne

Population : l'ensemble des 80 personnes

Caractère étudié : poids en kilogramme

Type de Caractère : variable statistique continue

Les données brutes sont :

68	84	75	82	68	90	62	88	76	93
73	79	88	73	60	93	71	59	85	75
61	65	75	87	74	62	95	78	63	72
66	78	82	75	94	77	69	74	68	60
96	78	89	61	75	95	60	79	83	71
79	62	67	97	78	85	76	63	71	75
65	80	73	57	88	78	62	76	53	74
86	67	73	81	72	63	76	75	85	77

Le caractère poids en kilogramme a pour valeurs minimum 53 et pour valeur maximum 97. La partition en classe doit donc couvrir au minimum l'intervalle $[53, 97]$. Néanmoins, on peut choisir un domaine de variation un peu plus large, par exemple l'intervalle $[50, 100]$.

La plus grande valeur de l'intervalle $[50, 100]$ est : 100

La plus petite valeur de l'intervalle $[50, 100]$ est : 50

L'étendue de l'intervalle $[50, 100]$ est : $100 - 50 = 50$

En fixant le nombre de classes à 10, l'amplitude constante des classes est :

$$\frac{50}{10} = 5$$

On construit la distribution de fréquences suivante :

Poids	Fréquences absolues (n_i)	Fréquences absolues cumulées		Fréquences relatives (f_i)	Fréquences relatives cumulées	
		croissantes	décroissantes		croissantes	décroissantes
[50, 55[	1	1	80	1,25%	1,25%	100%
[55, 60[	2	3	79	2,5%	3,75%	98,75%
[60, 65[	11	14	77	13,75%	17,5%	96,25%
[65, 70[	10	24	66	12,5%	30%	82,5%
[70, 75[	12	36	56	15%	45%	70%
[75, 80[	21	57	44	26,25%	71,25%	55%
[80, 85[	6	63	23	7,5%	78,75%	28,75%
[85, 90[	9	72	17	11,25%	90%	21,25%
[90, 95[	4	76	8	5%	95%	10%
[95, 100[	4	80	4	5%	100%	5%
Total	80			100%		

- La première classe $[50, 55[$ représente le nombre de personnes pesant entre 50 et 54 kilogrammes, la deuxième classe $[55, 60[$ représente le nombre de personnes pesant entre 55 et 59, etc.
- Le nombre de personnes pesant entre 60 et 64 kilogrammes est 11, ils représentent 13,75% des personnes pesées.
- Le nombre de personnes pesant au moins 70 kilogrammes est 56, ils représentent 70% des personnes pesées.
- Le nombre de personnes pesant au plus 84 kilogrammes est 63, ils représentent 78,75% des personnes pesées.

Remarque 2.3.3. On peut fixer le nombre de classes selon l'un des deux formules suivantes :

- Règle de **Sturge** : nombre de classes $= 1 + 3,3 \log(n)$
- Règle de **Yule** : nombre de classes $= 2,5 \sqrt[4]{n}$

où n représente l'effectif total de la population étudiée.

2.4 Représentations graphiques

Les tableaux statistiques permettent déjà une première analyse des caractères observés sur les individus d'une population. Pour avoir une idée de la manière dont se répartissent ces individus, il est souvent pratique de traduire ces tableaux sous différents types de graphe ou diagrammes.

2.4.1 Représentation d'une distribution à caractère qualitatif

Il existe plusieurs modes de représentation d'une distribution à caractère qualitatif, les plus employés sont le diagramme en tuyaux d'orgue et le diagramme circulaire.

2.4.1.1 Diagramme en tuyaux d'orgue

- les modalités du caractère sont placées sur une droite horizontale (attention : ne pas orienter cette droite car les modalités ne sont pas mesurables et il n'y a donc pas de relation d'ordre entre elles).
- les effectifs n_i (ou les fréquences f_i) sont placés sur un axe vertical. La hauteur du tuyau est proportionnelle à l'effectif correspondant.

Exemple:

Une enquête sur la nationalité des touristes visitant le Maroc a concerné un échantillon de 500 touristes. Les résultats obtenus sont présentés dans le tableau

suivant :

Nationalité	Nombre de touristes (fréquences absolues)	Pourcentage des touristes (fréquences relatives)
Française	85	17%
Allemande	106	21,2%
Italienne	62	12,4%
Hollandaise	44	8,8%
Belge	40	8%
Américaine	70	14,0%
Autre nationalités	93	18,6%
Total	500	100%




FIGURE 2.1 – Diagramme en tuyaux d'orgue

2.4.1.2 Diagramme circulaire ou graphique à secteurs

- L'effectif total est représenté par un disque.
- Chaque modalité est représentée par un secteur circulaire dont la surface (pratiquement : l'angle au centre) est proportionnelle à l'effectif correspondant : la totalité de 360° du cercle correspond à l'effectif total n de la population étudiée. Si n_i est l'effectif à représenter, il est traduit sur le cercle par un angle α tel que $\alpha = 360^\circ \times \frac{n_i}{n} = 360^\circ \times f_i$.

Exemple:

Pour le même exemple précédent, on doit déterminer pour chaque nationalité l'angle proportionnel à l'effectif correspondant.

Effectif total 500	correspond à 360°
85 français	correspondent à α_1
106 allemands	correspondent à α_2
62 italiens	correspondent à α_3
44 hollandais	correspondent à α_4
40 belges	correspondent à α_5
70 américains	correspondent à α_6
les 93 autres	correspondent à α_7

à l'aide d'une règle de trois, on calcule les différents angles :

$$\alpha_1 = \frac{85 \times 360}{500} = 61,2^\circ$$

$$\alpha_2 = \frac{106 \times 360}{500} = 76,32^\circ$$

$$\alpha_3 = \frac{62 \times 360}{500} = 44,64^\circ$$

$$\alpha_4 = \frac{44 \times 360}{500} = 31,68^\circ$$

$$\alpha_5 = \frac{40 \times 360}{500} = 28,8^\circ$$

$$\alpha_6 = \frac{70 \times 360}{500} = 50,4^\circ$$

$$\alpha_7 = \frac{93 \times 360}{500} = 66,96^\circ$$




FIGURE 2.2 – Diagramme circulaire

2.4.2 Représentation d'une distribution à caractère quantitatif

Avant toute tentative de représentation graphique des caractères quantitatifs, il faut distinguer entre variable discrète et variable continue (qui peut être classée ou regroupée en classes).

2.4.2.1 Représentation d'une variable statistique discrète

Il existe plusieurs modes de représentation graphique d'une variable statistique discrète, les plus employés sont le diagramme en bâtons et le polygone de fréquences.

• Diagramme en bâtons

Le diagramme en bâtons consiste à représenter les valeurs discrètes de la variable sur l'axe horizontal du graphique et on élève en chaque point un bâton dont la hauteur est proportionnelle à la fréquence correspondante.

Exemple:

La distribution des étudiants en fonction de nombre de personnes dans la famille

Nombre de personnes dans la famille	Nombre d'étudiants n_i
2	150
3	240
4	340
5	140
6	100
7 et plus	90
Total	1060




FIGURE 2.3 – Diagramme en bâtons

• Polygone de fréquences

Les polygones de fréquences sont construits en joignant par une ligne les sommets des bâtons du diagramme en bâtons.




FIGURE 2.4 – Polygone de fréquences

2.4.2.2 Représentation d'une variable statistique groupée en classes

La représentation graphique des fréquences simples d'une variable continue peut s'effectuer sous la forme d'un histogramme, en portant sur l'axe des abscisses les valeurs des classes du caractère, et en leur donnant les fréquences correspondantes.

• Principe de construction de l'histogramme

Pour chaque classe, on élève un rectangle ayant une base proportionnelle à l'intervalle de classe, donc ce sont les surfaces des rectangles qui ont une proportionnalité à l'effectif et non pas les hauteurs.

Dans la pratique deux cas peuvent se présenter

- Cas d'amplitude égale :

Exemple: La distribution des étudiants en fonction de la note du bac

Les notes	Le nombre d'étudiants	Amplitudes
[10, 12[	530	2
[12, 14[	250	2
[14, 16[	150	2
[16, 18[	100	2
[18, 20[	30	2
Total	1060	




FIGURE 2.5 – La distribution d'étudiants en fonction de la note du bac

- Cas des amplitudes inégales

Dans ce cas on respecte la proportionnalité des surfaces, il faut rectifier en conséquence les hauteurs.

Exemple:

Supposant que la distribution précédente se présente de la façon suivante

Les notes	Le nombre d'étudiants	Amplitudes
[10, 11.5[	450	1,5
[11.5, 13[	240	1,5
[13, 15[	170	2
[15, 17[	120	2
[17, 20[	80	3
Total	1060	

Alors, il est nécessaire de corriger les fréquences, en utilisant la formule suivante

$$\text{Fréquence corrigée} = \text{Fréquence} \times \frac{\text{amplitude normale}}{\text{amplitude de la classe}} \quad (2.1)$$

Avec : l'**amplitude normale**, c'est celle qui s'est répétée le plus.

Pour notre exemple, on choisit comme amplitude normale 1,5

Les notes	Le nombre d'étudiants (fréquences absolues)	Amplitudes	Fréquences corrigées
[10, 11.5[	450	1,5	$450 \times \frac{1,5}{1,5} = 450$
[11.5, 13[	240	1,5	$240 \times \frac{1,5}{1,5} = 240$
[13, 15[	170	2	$170 \times \frac{1,5}{2} = 127,5$
[15, 17[	120	2	$120 \times \frac{1,5}{2} = 90$
[17, 20[	80	3	$80 \times \frac{1,5}{3} = 40$
Total	1060		




FIGURE 2.6 – La distribution d'étudiants en fonction de la note du bac

2.5 Les paramètres de position

Les paramètres de position (ou de tendance centrale) permettent de savoir autour de quelles valeurs se situent les valeurs d'une variable statistique.

2.5.1 La médiane " Me "

La médiane est le nombre qui partage la population, dont les unités statistiques ont préalablement été classées par ordre croissant des valeurs (du caractère considéré), en deux sous populations égales.

2.5.1.1 Cas d'une variable statistique discrète

Pour une série statistique de n observations :

$$x_1, x_2, \dots, x_n$$

- Si le nombre d'observations est **impair**, la médiane est l'observation de rang $\frac{n+1}{2}$

$$M_e = x_{\frac{n+1}{2}}$$

Exemple: Une étude sur le nombre d'enfants d'un échantillon de 51 individus est présentée dans la distribution de fréquences suivante.

Nombre d'enfants	Nombre d'individus (fréquences absolues)
0	20
1	16
2	10
3	5
4	0
Total	51

On va tout d'abord transformer le tableau à une série statistique simple puis on préciser la valeur qui partage la série en deux moitiés.

$$\underbrace{0, \dots, 0}_{20}, \underbrace{1, \dots, 1}_{16}, \underbrace{2, \dots, 2}_{10}, \underbrace{3, 3, 3, 3, 3}_5$$

La médiane est la modalité "1 enfant" qui correspond à l'observation de

$$\text{rang } \frac{51+1}{2} = 26.$$

- Si le nombre d'observations est **pair**, la médiane est comprise entre l'observation de rang $\frac{n}{2}$ et l'observation de rang $\frac{n}{2} + 1$. On prend comme valeur de la médiane la moyenne arithmétique simple des deux observations

$$x_{\frac{n}{2}} \leq M_e \leq x_{\frac{n}{2}+1}$$

$$M_e = \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}$$

Exemple:

Soit la distribution du nombre d'employés observés chez 1000 Commerçants

Nombre d'employés	Nombre de Commerçants (n_i)	Fréquences cumulées croissantes
0	50	50
1	100	150
2	200	350
3	150	500
4	120	620
5	160	780
6	130	910
7	90	1000
Total	1000	

Le nombre d'observations, 1000, est pair, la médiane est comprise entre l'observation de rang 500 et l'observation de rang 501. On prend comme valeur de la médiane la moyenne arithmétique simple des deux observations

$$x_{500} \leq M_e \leq x_{501}$$

$$M_e = \frac{x_{500} + x_{501}}{2}$$

en consultant les fréquences absolues cumulées croissantes, x_{500} correspond à 3 et x_{501} correspond à 4. La médiane est donc :

$$M_e = \frac{3 + 4}{2} = 3,5$$

2.5.1.2 Cas d'une variable statistique continue groupée en classes

Pour des données groupées en classes, on détermine d'abord la classe médiane, et on précisera par la suite la médiane, en utilisant l'interpolation linéaire, autrement dit, on peut calculer la médiane par la formule suivante

$$M_e = b_i + a_i \times \frac{\frac{n}{2} - N_{i-1}}{n_i}$$

Avec :

b_i est la borne inférieure de la classe médiane

a_i est l'amplitude de la classe médiane

n est le nombre total des observations

N_{i-1} est la fréquence absolue cumulée croissante de la classe qui précède la classe médiane

n_i est la fréquence absolue de la classe médiane.

Exemple: La distribution de 50 étudiants en fonction de leurs tailles est représentée dans le tableau suivant :

Taille en cm	Le nombre d'étudiants	Fréquences cumulées croissantes
[150, 160[	15	15
[160, 170[	16	31
[170, 180[	10	41
[180, 190[	8	49
[190, 200[	1	50
Total	50	

En consultant les fréquences absolues cumulées croissantes, la classe médiane est la classe correspond à la fréquence cumulée $\frac{50}{2} = 25$, donc la classe médiane est l'intervalle [160, 170[.

Donc la Médiane est

$$M_e = 160 + 10 \times \frac{(25 - 15)}{16}$$

$$Me = 160 + \frac{100}{16} = 166,25$$

2.5.2 Le mode "Mo"

Le mode est la valeur (ou la modalité) qui correspond à la fréquence maximale dans la série ou la distribution. Le mode peut ne pas exister et s'il existe il peut ne pas être unique.

Dans le cas d'une variable discrète, le mode se détermine de la façon suivante :

Le nombre de personne dans la famille	Le nombre d'étudiants
2	150
3	240
4	340
5	140
6	100
7 et plus	90
Total	1060

Donc le mode est 4 qui correspond à la valeur la plus fréquente dans le tableau qui est 340 on écrit :

$$M_o = 4$$

Dans le cas d'une variable continue, le mode s'applique à la classe qui correspond à la fréquence maximale, celle-ci s'appelle "classe modale".

La valeur du mode dans ces conditions dépend de l'amplitude des classes et qu'il faut vérifier l'égalité des intervalles de classes.

$$M_o = b_i + a_i \frac{n_i - n_{i-1}}{(n_i - n_{i-1}) + (n_i - n_{i+1})}$$

Avec :

b_i est la borne inférieure de la classe modale

a_i est l'amplitude de la classe modale

n_i est la fréquence de la classe modale

n_{i-1} est la fréquence de la classe qui précède la classe modale

n_{i+1} est la fréquence de la classe qui succède la classe modale

Exemple:

La distribution de 50 étudiants en fonction de leurs tailles :

Taille en cm	Amplitudes	Nombre d'étudiants	n_i corrigée
[150, 165[	15	15	5
[165, 170[	5	6	6
[170, 175[	5	10	10
[175, 185[	10	16	8
[185, 200[	15	3	1
Total		50	

On va tout d'abord corriger les fréquences en utilisant la formule (2.1).

La classe modale donc est : [170, 175[

$$\text{Alors : } M_o = 170 + 5 \times \left(\frac{(10 - 6)}{(10 - 6) + (10 - 8)} \right) = 173,3 \text{ cm}$$

2.5.3 Les moyennes

2.5.3.1 Moyenne Arithmétique simple

Définition 2.5.1. La moyenne arithmétique, qu'on appelle tout simplement moyenne, est égale à la somme des valeurs prise par la variable étudiée divisée par le nombre d'observations, cette moyenne s'écrit en abrégé $\bar{X}$.

Remarque 2.5.1. Si la variable statistique est donnée sous forme d'une série statistique $(x_1, x_2, x_3, \dots, x_n)$, la moyenne arithmétique est le rapport :

$$\bar{X} = \frac{x_1 + x_2 + x_3 + \dots + x_n}{n} = \frac{\sum_{i=1}^n x_i}{n}$$

Exemple: Appliquons cette définition au calcul de la moyenne de la série suivante (4, 0, 1, 1, 2, 2, 2, 3, 3, 4, 2, 3, 4, 5, 2, 1, 3, 3, 4, 5). On a donc :

$$\begin{aligned} \bar{X} &= \frac{\sum_{i=1}^{20} x_i}{20} = \frac{4 + 0 + 1 + 1 + 2 + 2 + 2 + 3 + 3 + 4 + 2 + 3 + 4 + 5 + 2 + 1 + 3 + 3 + 4 + 5}{20} \\ &= \frac{54}{20} = 2,7 \end{aligned}$$

2.5.3.2 Moyenne Arithmétique pondérée

Lorsque la variable statistique est donnée sous forme de tableau de distribution, c'est-à-dire, quand les valeurs des variables sont affectées de fréquence, la

moyenne arithmétique s'écrit de la façon suivante

$$\bar{X} = \frac{\sum_{i=1}^k n_i x_i}{\sum_{i=1}^k n_i}$$

avec la notation n_i représente les fréquences absolues des modalités.

Remarque 2.5.2. La somme varie cette fois de 1 à k , avec k représente le nombre de modalités de la série statistique. Dans le cas où aucune valeur n'est répétée $k = n$. Sinon $k < n$.

Exemple: - cas d'une variable discrète

Le nombre de personne dans la famille	Le nombre d'étudiants	$n_i x_i$
2	150	300
3	240	720
4	340	1360
5	140	700
6	100	600
7	30	210
8	25	200
9	20	180
10	15	150
TOTAL	1060	4420

Donc la moyenne de nombre de personne dans les familles des étudiants est :

$$\bar{X} = \frac{4420}{1060} = 4,16$$

Exemple: - cas d'une variable continue

Les notes	Le nombre d'étudiants n_i	point central c_i	$n_i c_i$
[10, 12[	530	11	5830
[12, 14[	250	13	3250
[14, 16[	150	15	2250
[16, 18[	100	17	1700
[18, 20[	30	19	570
TOTAL	1060		13600

Donc la moyenne des notes des étudiants est :

$$\bar{X} = \frac{13600}{1060} = 12,83$$

2.6 Les paramètres de dispersion

Les paramètres de position sont insuffisants pour caractériser complètement une série. Par exemple, deux séries différentes ayant la même moyenne, ne se répartissent pas nécessairement de la même manière autour de cette moyenne. Elles sont plus ou moins étalées, ce qui sera décrit par les caractéristiques de dispersion. Un paramètre de dispersion se rapporte à la différence de deux valeurs du caractère alors qu'un paramètre de position représente une valeur du caractère. On distingue les notions suivantes

- **déviatio**n : différence algébrique de deux valeurs du caractère, par exemple $x_i - \bar{X}$;
- **écart** : valeur absolue de la différence de deux valeurs du caractère, par exemple $|x_i - \bar{X}|$;
- **Intervalle de variation, étendue (ou range)** : différence entre les valeurs extrêmes du caractère ;
- **écart interquartile** : différence entre le 3^{me} et le 1^{er} quartiles, c'est à dire $Q_3 - Q_1$ (voir la section 2.6.2 pour comprendre ce que signifient les quartiles).

Rappel : la somme des déviations d'un ensemble de données x_i par rapport à leur valeur moyenne $\bar{X}$, est nulle. En effet,

$$\sum_{i=1} n_i(x_i - \bar{X}) = \sum_{i=1} n_i x_i - n\bar{X} = 0 \quad \text{où} \quad \bar{X} = \frac{1}{n} \sum_{i=1} n_i x_i$$

2.6.1 Les quantiles

Définition 2.6.1. *Les quantiles sont des paramètres qui nous renseignent sur la dispersion des valeurs de la variable autour de la médiane.*

Nous savons que la médiane divise la distribution en deux parties égales. Il existe d'autres indicateurs utiles :

- Les quartiles qui divise la distribution en quatre (4) parties égales
- Les déciles qui divise la distribution en dix (10) parties égales
- Les centiles qui divise la distribution en cent (100) parties égales

Les quartiles sont notés Q_1 , Q_2 et Q_3

- Le 1^{er} **quartile** Q_1 est la valeur du caractère telle que %25 des observations lui soient inférieures et %75 des observations lui soient supérieures
- Le 3^{me} **quartile** Q_3 est la valeur du caractère telle que %75 des observations lui soient inférieures et %25 des observations lui soient supérieures
- Le 2^{me} **quartile** Q_2 correspond à la médiane

Remarque 2.6.1. *La médiane est le 2^{me} quartile, le 5^{me} décile et le 50^{me} centile.*

L'intervalle interquartile ou l'Ecart interquartile est la différence entre Q_3 et Q_1 , on le note : $I_q = Q_3 - Q_1$, cet intervalle contient %50 des observations, c'est un indicateur très important en de dispersion

2.6.2 Indicateurs de dispersion par rapport à la moyenne

2.6.2.1 La variance

La définition de la variance des n valeurs associées aux n unités statistiques de la population est donnée par la formule suivante :

- **cas d'une série statistique :**

$$V(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2$$

- **cas d'une distribution de fréquences d'une variable statistique discrète (resp. variable statistique continue) :**

$$V(X) = \frac{1}{n} \sum_{i=1}^k n_i (x_i - \bar{X})^2$$

où :

n : est la taille de la population

k : est le nombre de valeurs (resp. nombre de classes)

n_i : est la fréquence absolue, correspondant à la $i^{\text{ème}}$ valeur (resp. $i^{\text{ème}}$ classe)

x_i : est la $i^{\text{ème}}$ valeur observée (resp. le centre de la $i^{\text{ème}}$ classe)

$\bar{X}$: est la moyenne arithmétique simple (resp. pondérée).

Exemple:

- **cas d'une variable discrète**

Le tableau suivant présente la distribution de 400 familles selon le nombre d'enfants

Nombre d'enfants x_i	Nombre de familles (fréquences absolues) n_i	$n_i x_i$	$(x_i - \bar{X})$	$n_i (x_i - \bar{X})^2$
0	50	0	-2,2875	261,633
1	75	75	-1,2875	124,324
2	80	160	-0,2875	6,6125
3	115	345	0,7125	58,380
4	65	260	1,7125	190,623
5	15	75	2,7125	110,365
Total	400	915		751,9373

$$\bar{X} = \frac{1}{400} \sum_{i=1}^6 n_i x_i = \frac{915}{400} = 2,2875$$

$$V(X) = \frac{1}{400} \sum_{i=1}^6 n_i (x_i - \bar{X})^2 = \frac{751,9373}{400} = 1,8798$$

- **cas d'une variable continue**

Le tableau suivant présente la distribution de 200 bébés selon le poids (en g)

Poids en g	Nombre de bébés (fréquences absolues) n_i	Point central c_i	$n_i c_i$	$(c_i - \bar{X})$	$n_i(c_i - \bar{X})^2$
[250, 300[	5	275	1375	-127,5	81282,25
[300, 350[	30	325	9750	-77,5	180187,5
[350, 400[	50	375	18750	-27,5	37812,5
[400, 450[	80	425	34000	22,5	40500
450 g et plus	35	475	16625	72,5	183968,75
Total	200		80500		523750

$$\bar{X} = \frac{1}{200} \sum_{i=1}^5 n_i c_i = \frac{80500}{200} = 402,5 \text{ g}$$

$$V(X) = \frac{1}{200} \sum_{i=1}^5 n_i (c_i - \bar{X})^2 = \frac{523750}{200} = 2618,75$$

Remarque 2.6.2. On peut aussi calculer la variance à partir d'une autre formule, dont on montre qu'elle est équivalente à la formule précédente. Cette formule est :

$$V(X) = \frac{1}{n} \sum_{i=1}^k n_i x_i^2 - \bar{X}^2$$

Dans le cas continu, on remplace x_i par c_i centres de classes.

La variance n'est pas d'une grande utilité en soi. On peut seulement dire que plus elle est élevée, plus la dispersion autour de la moyenne est élevée. Mais elle a l'inconvénient de ne pas être dans la même unité que la série de donnée car les valeurs sont élevées au carré. C'est pour cette raison qu'on utilise la variance comme calcul intermédiaire pour obtenir l'écart-type et le coefficient de variation.

2.6.2.2 L'écart-type

La définition de l'écart-type d'une série (ou distribution) statistique est donnée par la formule :

$$\sigma_X = \sqrt{V(X)}$$

Remarque 2.6.3.

- Si σ_X est faible, cela signifie que les valeurs sont assez concentrées autour de la moyenne $\bar{X}$.
- Si σ_X élevé, cela veut dire au contraire que les valeurs sont plus dispersées autour de la moyenne $\bar{X}$.
- L'écart-type ne peut comparer la dispersion de deux ou plusieurs variables statistiques que si elles sont de même nature, c'est à dire, elles ont les mêmes unités.

Exemple:

Les tableaux suivants présentent le salaire horaire des employés de deux entreprises

Entreprise 1

Salaire horaire	Nombre d'employés n_i	Point central	$n_i x_i^2$
[30, 50[	33	40	52800
[50, 70[	35	60	126000
[70, 90[	19	80	121600
Total	87		300400

$$\bar{X} = 56,78 \text{ dh/h}$$

$$V(X) = \frac{\sum_{i=1}^3 n_i x_i^2}{\sum_{i=1}^3 n_i} - \bar{X}^2 = \frac{300400}{87} - 56,78^2 = 228,91$$

$$\sigma_X = \sqrt{228,91} = 15,13 \text{ dh/h}$$

Entreprise 2

Salaire horaire	Nombre d'employés n_i	Point central	$n_i x_i^2$
[10, 30[	20	20	8000
[30, 50[	18	40	28800
[50, 70[	20	60	72000
[70, 90[	14	80	89600
[90, 110[	15	100	150000
Total	87		348400

$$\bar{X} = 56,78 \text{ dh/h}$$

$$V(X) = \frac{\sum_{i=1}^5 n_i x_i^2}{\sum_{i=1}^5 n_i} - \bar{X}^2 = \frac{348400}{87} - 56,78^2 = 780,63$$

$$\sigma_X = \sqrt{780,63} = 27,94 \text{ dh/h}$$

L'écart-type de l'entreprise 2 est plus élevé que celui de l'entreprise 1. Les salaires sont donc plus dispersés dans la deuxième entreprise

2.6.2.3 Le coefficient de variation

L'écart-type est un outil intéressant pour mesurer la dispersion d'une série, ainsi que nous venons de le voir. Mais il possède une limite : Il est exprimé dans l'unité de la variable dont il mesure la dispersion des valeurs.

Ainsi, par exemple, si on veut comparer les dispersions de deux séries (ou distributions) qui sont exprimées dans des unités différentes, on ne peut pas. D'où l'idée de calculer **le coefficient de variation** qui est égal à l'écart-type divisé par la moyenne, c'est-à-dire :

$$C_V = \frac{\sigma_X}{\bar{X}}, \quad 0 \leq C_V \leq 1 \text{ ou } C_V\% = \frac{\sigma_X}{\bar{X}} \times 100\%, \quad 0 \leq C_V \leq 100\%$$

Exemple:

On a relevé le poids et la taille d'un échantillon de 200 personnes. Les résultats sont présentés dans les tableaux 1 et 2

Tableau 1

Poids (en Kg)	Nombre de personnes
[60, 62[	10
[62, 64[	36
[64, 66[	84
[66, 68[	54
[68, 70[	16
Total	200

$$\bar{X} = \frac{\sum_{i=1}^5 n_i x_i}{\sum_{i=1}^5 n_i} = 65,30 \text{ Kg}$$

$$V(X) = \frac{\sum_{i=1}^5 n_i x_i^2}{\sum_{i=1}^5 n_i} - \bar{X}^2 = 3,79 \text{ Kg}^2$$

$$\sigma_X = \sqrt{V(X)} = 1,95 \text{ Kg}$$

$$C_V = \frac{\sigma_X}{\bar{X}} = 0,03$$

Tableau 2

Taille (en cm)	Nombre de personnes
[118, 128[	15
[128, 138[	25
[138, 148[	45
[148, 158[	60
[158, 168[	25
[168, 178[	20
[178, 188[	10
Total	200

$$\bar{X} = \frac{\sum_{i=1}^7 n_i x_i}{\sum_{i=1}^7 n_i} = 150,75 \text{ cm}$$

$$V(X) = \frac{\sum_{i=1}^7 n_i x_i^2}{\sum_{i=1}^7 n_i} - \bar{X}^2 = 232,44 \text{ cm}^2$$

$$\sigma_X = \sqrt{V(X)} = 15,25 \text{ cm}$$

$$C_V = \frac{\sigma_X}{\bar{X}} = 0,10$$

Le coefficient de variation de la taille est supérieur à celui du poids, la taille est donc plus dispersée que le poids

Remarque 2.6.4.

- Si $0,5 < C_V < 1$, la dispersion est forte (ou la série est fortement dispersée).
- Si $0 < C_V < 0,5$, la dispersion est faible (ou la série est faiblement dispersée).
- Si $C_V \approx 0,5$, la dispersion est mitigée.
- Si $C_V \approx 1$, la dispersion est parfaite (ou la série est parfaitement dispersée).
- Si $C_V \approx 0$, la dispersion est nulle (ou la série est nullement dispersée).

2.6.3 Moments d'une série statistique

Définition 2.6.2. On appelle moment d'ordre r par rapport à une constante x_0 , la moyenne arithmétique des puissances r^{ime} des déviations des valeurs du caractère par rapport à x_0 :

$$m_r = \frac{1}{N} \sum_{i=1} n_i (x_i - x_0)^r$$

Cas particuliers :

a) $x_0 = 0$, $r = 1$, le moment n'est autre que la moyenne arithmétique

$$m_r = \frac{1}{N} \sum_{i=1} n_i x_i$$

b) $x_0 = \bar{X}$, $r = 2$, le moment n'est autre que la variance

$$m_r = \frac{1}{N} \sum_{i=1} n_i (x_i - \bar{X})^2$$

Remarque 2.6.5. Tout comme les paramètres de dispersion permettent de représenter la distribution statistique plus fidèlement que les seuls paramètres de position, les moments d'ordre r supérieurs à 2 améliorent encore cette représentation. Toute fois, on se limite généralement à $r = 1$ et $r = 2$.

2.6.4 Changement d'origine et d'unité**2.6.4.1 Changement d'origine et d'unité**

Définition 2.6.3. :

- On appelle changement d'origine l'opération consistant à ajouter la même quantité $b \in \mathbb{R}$ à toutes les observations : $y_i = x_i + b, i = 1, \dots, n$.
- On appelle changement d'unité l'opération consistant à multiplier par la même quantité $a \in \mathbb{R}$ toutes les observations : $y_i = a \times x_i, i = 1, \dots, n$.
- On appelle changement d'origine et d'unité l'opération consistant à multiplier toutes les observations par la même quantité $a \in \mathbb{R}$ puis à ajouter la même quantité $b \in \mathbb{R}$ à toutes les observations : $y_i = a \times x_i + b, i = 1, \dots, n$.

Théorème 2.6.1. *Si on effectue un changement d'origine et d'unité sur une variable X , alors*

- *Sa moyenne est affectée du même changement d'origine et d'unité, $\bar{y} = a\bar{x} + b$*
- *Sa variance et son écart-type sont affectés par le changement d'unité et pas par le changement d'origine, $V_y = a^2V_x$ et $\sigma_y\sqrt{V_y} = |a|\sigma_x$*

Preuve : Si $y_i = a \times x_i + b$, alors

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n (a \times x_i + b) = a \times \left(\frac{1}{n} \sum_{i=1}^n x_i \right) + b = a\bar{x} + b$$

$$V_y = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n (a \times x_i + b - a\bar{x} - b)^2 = a^2 \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = a^2 V_x$$

$$\sigma_y = \sqrt{V_y} = \sqrt{a^2 V_x} = |a| \sigma_x$$

Remarque 2.6.6. :

- *Les paramètres de position (mode, médiane et moyenne) sont tous affectés par un changement d'origine et d'unité.*
- *Les paramètres de dispersion sont tous affectés par un changement d'unité mais pas par un changement d'origine (sauf le coefficient de variation).*

2.6.4.2 Centrer et réduire une variable

Centrer et réduire une variable statistique quantitative X consiste à la remplacer par la variable : $\frac{X - \bar{X}}{\sigma(X)}$

$X - \bar{X}$ pour la centrer (moyenne 0). La variable : $\frac{X - \bar{X}}{\sigma(X)}$ a pour moyenne arithmétique 0 elle est centrée.

Diviser par l'écart-type $\sigma(X)$ pour la réduire (écart-type = 1). La variable $\frac{X - \bar{X}}{\sigma(X)}$ a pour variance et écart-type 1 elle est réduite.

2.7 Paramètre de forme

2.7.0.1 Symétrie et asymétrie

Une distribution est dite symétrique si le mode, la médiane et la moyenne sont confondus. Une distribution qui n'est pas symétrique est dite asymétrique

Remarque 2.7.1. *Une variable statistique est symétrique si ses valeurs sont réparties de manière symétrique autour de la moyenne c'est à dire si le polygone des fréquences a la forme d'une cloche comme dans la figure ci-après.*

A la différence de la médiane et du mode, la moyenne arithmétique est fortement influencée par les valeurs extrêmes. Lorsque les valeurs sont distribuées de manière symétrique, la moyenne arithmétique coïncide avec la médiane et le mode. Lorsque la distribution est asymétrique, la moyenne arithmétique dépasse




FIGURE 2.7 – Clôche

la médiane si les valeurs extrêmes sont élevées et se situe en dessous de la médiane si les valeurs extrêmes sont basses.

Une distribution est dite asymétrique à droite, si la courbe du polygone des fréquences est étalée à droite, on a généralement : $\text{mode} < \text{médiane} < \text{moyenne}$.

Une distribution est dite asymétrique à gauche, si la courbe du polygone des fréquences est étalée à gauche, on a généralement : $\text{moyenne} < \text{médiane} < \text{mode}$.

La figure ci-dessous illustre ces différents cas lorsque la distribution ne présente qu'un seul mode.




FIGURE 2.8 – symétrie et asymétrie

Symétrie : $\text{mode} = \text{médiane} = \text{moyenne}$

Symétrie à droite : $\text{mode} < \text{médiane} < \text{moyenne}$

Symétrie à gauche : $\text{moyenne} < \text{médiane} < \text{mode}$

Chapitre 3

Statistique descriptive bidimensionnelle

L'étude statistique peut se porter sur deux caractères présents dans tous les membres de la population. Ces deux caractères sont représentés par deux variables X et Y . On peut utiliser l'information dont on dispose pour étudier la liaison qui existe éventuellement entre ces deux caractères.

3.1 Représentation graphique du nuage de points

Une étude simultanée sur deux variables quantitatives X et Y sur une population de n individus a donné les différents points de mesures :

$$(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots, (x_{n-1}, y_{n-1}), (x_n, y_n)$$

Ces données sont représentées par paires. le premier élément de la paire correspond à la valeur prise par la variable X et le second par Y . x_k et $y_k, k = 1, \dots, n$ sont des valeurs observées.

On représente une distribution statistique à deux caractères quantitatifs par l'ensemble des points A_k , de coordonnées $(x_k, y_k), k = 1 \dots n$, chaque individu correspond à un point du plan.

On appelle nuage de points l'ensemble des points A_k , de coordonnées $(x_k, y_k), k = 1, \dots, n$. La représentation graphique du nuage de points est essentielle pour déterminer s'il existe ou non une relation entre les variables X et Y .

On représente sur l'axe des abscisse les mesures $x_k, k = 1 \dots, n$ et sur l'axe des ordonnées les mesures $y_k, k = 1 \dots, n$ est le points A_k correspond à la paire (x_k, y_k) .

Exemple:

Les notes de mathématiques (X) et de statistique (Y) obtenues par 12 étudiants

Numéro d'étudiant	1	2	3	4	5	6	7	8	9	10	11	12
Note de mathématique	11	14	09	12	10	06	15	12	10	10	08	13
Note de statistique	10	15	11	11	09	08	14	13	11	12	10	12

Le nuage de points est illustré ci-dessous, où chaque étudiant est représenté par un point ayant pour abscisse x_i et pour ordonnée y_i .




FIGURE 3.1 – Le nuage de points

3.2 Moments et la covariance

Définition 3.2.1. On définit la covariance de deux variables statistiques par la moyenne arithmétique des produits des différences des observations par rapport à leur moyenne :

- Cas d'une série statistique double :

$$x_1, x_2, x_3, \dots, x_i, \dots, x_n$$

$$y_1, y_2, y_3, \dots, y_i, \dots, y_n$$

$$COV(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{X}) \times (y_i - \bar{Y})}{n}$$

- Cas d'un tableau de contingence :

X possède k modalités : $x_1, x_2, x_3, \dots, x_i, \dots, x_k$

Y possède p modalités : $y_1, y_2, y_3, \dots, y_i, \dots, y_p$

$$COV(X, Y) = \frac{\sum_{i=1}^k \sum_{j=1}^p n_{ij} (x_i - \bar{X}) \times (y_j - \bar{Y})}{n}$$

Remarque 3.2.1. La covariance est positive si X et Y ont tendance à varier dans le même sens, et négative si elles ont tendance à varier en sens contraire. Si les variables sont indépendantes, alors $Cov(x, y) = 0$.

Proposition 3.2.1. Si $X = Y$, alors $COV(X, Y) = V(X) = (\sigma_X)^2$

Formule développée de la variance :

Définition 3.2.2. La covariance est égale à la différence entre la moyenne des produits et le produit des moyennes. Dans le cas d'un tableau de contingence on a :

$$COV(X, Y) = \frac{\sum_{i=1}^k \sum_{j=1}^p n_{ij} x_i y_j}{n} - \bar{X} \bar{Y}$$

Exemple:

On a relevé les notes de mathématiques (X) et de statistique (Y) obtenues par 12 étudiants à un examen final.

La série statistique double est :

Numéro d'étudiant	1	2	3	4	5	6	7	8	9	10	11	12
Note de mathématique (x_i)	11	14	09	12	10	06	15	12	10	10	08	13
Note de statistique (y_i)	10	15	11	11	09	08	14	13	11	12	10	12

$$\sum_{i=1}^{12} x_i = 130$$

$$\sum_{i=1}^{12} y_i = 136$$

$$\sum_{i=1}^{12} x_i y_i = 1521$$

$$\bar{X} = \frac{130}{12} = 10,83$$

$$\bar{Y} = \frac{136}{12} = 11,33$$

$$COV(X, Y) = \frac{\sum_{i=1}^{12} x_i y_i}{12} - \bar{X} \bar{Y} = \frac{1521}{12} - 10,83 \times 11,33 = 4,05$$

La covariance est positive, la relation entre les notes de mathématiques et les notes de statistique est croissante, c'est à dire un étudiant qui a une bonne note en mathématique a, en moyenne, une bonne note en statistique et un étudiant qui a une mauvaise note en mathématique a, en moyenne, une mauvaise note en statistique.

3.3 Le coefficient de corrélation

Définition 3.3.1. Le coefficient de corrélation linéaire, désigné par r ou r_{XY} , a pour objet de mesurer l'intensité de la liaison linéaire entre deux variables statistiques X et Y :

$$r = \frac{COV(X, Y)}{\sigma_X \sigma_Y}$$

Dans cette expression, $COV(X, Y)$ est la covariance et σ_X et σ_Y sont les écarts-types des distributions marginales de X et Y .

Cette définition montre que le coefficient de corrélation possède le même signe que la covariance et qu'il est toujours compris entre -1 et 1

- $r = 1$, dans ce cas les points se trouvent tous sur une même droite croissante, on parle de corrélation linéaire positive parfaite.
- $r = -1$, dans ce cas les points se trouvent tous sur une même droite décroissante, on parle de corrélation linéaire négative parfaite.

- $r = 0$, dans ce cas il n'y a aucune dépendance linéaire entre les deux variables, on parle de corrélation linéaire nulle.
- $-1 < r < 0$, dans ce cas les deux variables varient en sens inverses, la relation linéaire est faible ou forte selon que le coefficient de corrélation linéaire est proche de 0 ou -1
- $0 < r < 1$, dans ce cas les deux variables varient dans le même sens, la relation linéaire est faible ou forte selon que le coefficient de corrélation linéaire est proche de 0 ou 1.

Pour l'interprétation de la valeur de r , référons-nous à la figure ci-dessous.




FIGURE 3.2 – Exemples de nuages de points et coefficients de corrélation

Remarque 3.3.1. *Le coefficient de corrélation linéaire est indépendant des unités de mesure.*

3.3.1 Coefficient de détermination

Définition 3.3.2. *Le coefficient de détermination est le carré du coefficient de corrélation linéaire. Il mesure la part de la variation d'une variable expliquée par l'autre variable.*

$$r^2 = \frac{(\text{COV}(X, Y))^2}{\sigma_X^2 \sigma_Y^2}$$

Remarque 3.3.2. *Le coefficient de détermination est indépendant des unités de mesure.*

Exemple:

Les notes de mathématiques (X) et de statistique (Y) obtenues par 12 étudiants.

Numéro d'étudiant	1	2	3	4	5	6	7	8	9	10	11	12
Note de mathématique (x_i)	11	14	09	12	10	06	15	12	10	10	08	13
Note de statistique (y_i)	10	15	11	11	09	08	14	13	11	12	10	12

$$\sum_{i=1}^{12} x_i = 130$$

$$\sum_{i=1}^{12} y_i = 136$$

$$\sum_{i=1}^{12} x_i^2 = 1480$$

$$\sum_{i=1}^{12} y_i^2 = 1586$$

$$\sum_{i=1}^{12} x_i y_i = 1521$$

$$\bar{X} = \frac{130}{12} = 10,83$$

$$\bar{Y} = \frac{136}{12} = 11,33$$

$$V(X) = \frac{1480}{12} - 10,83^2 = 6,04$$

$$\sigma_X = \sqrt{6,04} = 2,46$$

$$V(Y) = \frac{1586}{12} - 11,33^2 = 3,80$$

$$\sigma_Y = \sqrt{3,80} = 1,95$$

$$COV(X, Y) = \frac{\sum_{i=1}^{12} x_i y_i}{12} - \bar{X} \bar{Y} = \frac{1521}{12} - 10,83 \times 11,33 \simeq 4,05$$

$$r = \frac{COV(X, Y)}{\sigma_X \times \sigma_Y} = \frac{4,05}{2,46 \times 1,95} \simeq 0,84$$

Le coefficient de corrélation linéaire est positif et relativement proche de 1, il y a donc une corrélation linéaire croissante relativement forte entre les notes de mathématiques et les notes de statistique

$$r^2 = 0,84^2 = 0,71$$

Les notes d'une matière (mathématique ou statistique) expliquent 71% de la variation des notes de l'autre matière.

3.4 Les droites de régression

Le coefficient de corrélation mesure la dépendance linéaire des variables. Si cette dépendance est bonne, on peut exprimer la variable Y comme fonction linéaire de X . C'est à dire que les valeurs y_i peuvent être remplacées par des valeurs calculées qui sont fonctions des x_i . Plus précisément : $y_1 = ax_1 + b, y_2 = ax_2 + b, y_3 = ax_3 + b, \dots, y_n = ax_n + b$. Il reste donc à déterminer les valeurs des paramètres a et b , qui désignent respectivement la pente (ou coefficient de régression) et l'ordonnée à l'origine de la droite de régression.

La variable X est dite variable explicative ou variable indépendante. La variable Y est dite variable à expliquer ou variable dépendante.

Pour déterminer les paramètres a et b , on peut utiliser la méthode des moindres carrés. Cette méthode consiste à minimiser la somme des carrés des différences entre les valeurs observées, y_i , et les valeurs estimées $\hat{y}_i$ par l'équation de la droite de régression :

$$\hat{y}_i = ax_i + b$$

C'est à dire déterminer les constantes a et b telle que l'expression $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ soit minimum.

Ce problème est un problème classique de minimisation dont la solution est :

$$a = \frac{COV(X, Y)}{\sigma_X^2} \text{ et } b = \bar{Y} - a\bar{X}$$

Définition 3.4.1. La droite de régression de Y en fonction de X , selon la méthode des moindres carrés est la droite d'équation : $Y = aX + b$ telle que

$$a = \frac{COV(X, Y)}{\sigma_X^2} \text{ et } b = \bar{Y} - a\bar{X}$$

Remarque 3.4.1.

- Comme la droite de régression de Y en fonction de X , la droite de régression de X en fonction de Y est la droite d'équation : $X = a'Y + b'$ telle que :

$$a' = \frac{COV(X, Y)}{\sigma_Y^2} \text{ et } b' = \bar{X} - a'\bar{Y}$$

- Une droite de régression passe par le point moyen $(\bar{X}, \bar{Y})$

Exemple:

Les notes de mathématiques (X) et de statistique (Y) obtenues par 12 étudiants

Numéro d'étudiant	1	2	3	4	5	6	7	8	9	10	11	12
Note de mathématique (x_i)	11	14	09	12	10	06	15	12	10	10	08	13
Note de statistique (y_i)	10	15	11	11	09	08	14	13	11	12	10	12
x_i^2	121	196	81	144	100	36	225	144	100	100	64	169
y_i^2	100	225	121	121	81	64	196	169	121	144	100	144
$x_i y_i$	110	210	99	132	90	48	210	156	110	120	80	156

$$\sum_{i=1}^{12} x_i = 130$$

$$\sum_{i=1}^{12} y_i = 136$$

$$\sum_{i=1}^{12} x_i^2 = 1480$$

$$\sum_{i=1}^{12} y_i^2 = 1586$$

$$\sum_{i=1}^{12} x_i y_i = 1521$$

$$\overline{X} = \frac{130}{12} = 10,83$$

$$\overline{Y} = \frac{136}{12} = 11,33$$

$$V(X) = \frac{1480}{12} - 10,83^2 = 6,04$$

$$\sigma_X = \sqrt{6,04} = 2,46$$

$$V(Y) = \frac{1586}{12} - 11,33^2 = 3,80$$

$$\sigma_Y = \sqrt{3,80} = 1,95$$

$$COV(X, Y) = \frac{\sum_{i=1}^{12} x_i y_i}{12} - \overline{X} \overline{Y} = \frac{1521}{12} - 10,83 \times 11,33 \simeq 4,05$$

Connaissant la note de mathématique d'un étudiant, on peut estimer sa note de statistique par la droite d'équation : $Y = aX + b$ telle que :

$$a = \frac{COV(X, Y)}{\sigma_X^2} = \frac{4,05}{6,04} = 0,67$$

$$b = \overline{Y} - a\overline{X} = 11,33 - 0,67 \times 10,83 = 4,07$$

$$y_i = 0,67x_i + 4,07$$

Connaissant la note de statistique d'un étudiant, on peut estimer sa note de mathématique par la droite d'équation : $X = a'Y + b'$ telle que :

$$a' = \frac{COV(X, Y)}{\sigma_Y^2} = \frac{4,05}{3,80} = 1,07$$

$$b' = \overline{X} - a'\overline{Y} = 10,83 - 1,07 \times 11,33 = -1,29$$

$$x_i = 1,07y_i - 1,29$$